

Sparse Autoencoder 기반 GNN 그래프 임베딩의

화학적 해석 가능 표현 분해

유진영⁰¹, 노다솜⁰², 김성훈⁰¹, 권선영^{1,2,3*}
¹부산대학교 의생명융합공학부², 부산대학교 정보융합공학과,
³부산대학교 인공지능융합연구센터
{yoo122333, ds.noh, tjdgns1502, sy.kwon}@pusan.ac.kr

Disentangling Chemical Representations in GNN Graph Embeddings via Sparse Autoencoders

Jinyoung Yu⁰¹, Dasom Noh⁰², Seong Hun Kim⁰¹, Sunyoung Kwon^{1,2,3*}
¹School of Biomedical Convergence Engineering,
²Dept. of Information Convergence Engineering,
³Center for Artificial Intelligence Research, Pusan National University

요약

분자 그래프 신경망(graph neural network, GNN)의 그래프 단위 임베딩은 다양한 화학 정보가 저차원에 압축된 밀집 표현으로, 단일 차원이 여러 화학 개념과 동시에 연결되는 특성 때문에 해석이 어렵다. 본 연구에서는 GEM 모델의 32차원 그래프 임베딩 위에 JumpReLU sparse autoencoder (SAE)를 학습하여 1,024차원의 희소 특징 사전을 구성하고, 화학적으로 의미 있는 표현 분리를 분석하였다. INC15 데이터셋의 220만 분자에 대해 SAE를 학습한 결과, 분자당 평균 약 5% (52/1,024)의 특징만 활성화되는 희소 구조가 형성되었으며, 희소표현과 복원표현의 분류 성능은 원본 표현과 거의 동일하게 유지되었다. 또한 일부 SAE 특징은 코르티코스테로이드, 흡입 마취제, 안트라사이클린 등 특정 약물 클래스와 정렬된 희소 축으로 작동하였다. 이러한 결과는 GNN 기반 밀집 임베딩이 SAE를 통해 화학적으로 구조화된 희소 표현으로 분해될 수 있음을 시사한다.

1. 서론

자연어 처리 분야에서 희소 오토인코더(sparse autoencoder, SAE)는 신경망의 다의적 활성을 단일 의미 특성으로 분해하는 방법으로 활용되어 왔다[1,2]. SAE는 활성화 벡터를 과완비(over-complete) 희소 사전(sparse dictionary)으로 표현하여, 해석 가능한 단일 개념에 대응하는 특성(feature)을 학습한다. 이러한 접근은 주로 대규모 언어모델을 중심으로 발전해왔으며, 단백질 서열과 같은 시퀀스 기반 표현에도 확장되어 활용되고 있다. 최근에는 화학 언어모델 SMI-TED에 SAE를 적용한 연구[6]가 보고되었으나, 이들 대부분은 여전히 시퀀스 기반 표현에 국한되어 있다.

반면, 분자 그래프 신경망은 노드와 엣지 간의 구조적 관계를 반영한 임베딩을 학습하며, 이 과정에서 하나의 차원에 여러 화학적 개념이 중첩되는 표현이 나타날 수 있어 단일 차원의 의미를 해석하기 어렵다. 이러한 특성으로 인해 분자 그래프 임베딩에 대한 해석 가능성 확보는 여전히 도전적인 문제이며, 이에 대한 SAE 기반 접근은 아직 제한적으로 이루어져 있다. 본 연구에서는 SAE를 적용하여 분자 그래프 신경망 임베딩의 해석 가능성을 분석한다. 이를 위해 GEM의 32차원 그래프 임베딩에 JumpReLU SAE[3]를 적용하여 밀집된 표

현을 희소 특성 공간으로 변환하고, 분자별로 선택적으로 활성화되는 구조를 유도한다. 나아가, 학습된 SAE 특성(feature)이 특정 약물 클래스 수준의 의미적 구조를 반영하는지를 분석한다.

2. 관련 연구

2.1 자연어 모델의 Sparse Autoencoder

Bricken 등[1]은 트랜스포머의 내부 표현을 과완비 희소 사전으로 분해하여, 단일 개념에 대응하는 특성을 추출할 수 있음을 보였다. Templeton 등[2]은 이를 대규모 언어모델에 확장하여 추상적 개념이나 안전 관련 표현과 같은 고수준 의미도 분리 가능함을 확인하였다. 이후 JumpReLU SAE[3]는 학습 가능한 임계값을 도입하여 재구성 성능과 희소성(sparsity) 간의 균형을 개선하였으며, SAE-Lens[4]는 이러한 SAE의 학습과 해석을 지원하는 표준화된 오픈소스 도구를 제공한다.

2.2 화학·생체분자 표현에 대한 SAE 적용

화학·생체분자 표현에 SAE를 적용한 연구로는 SMI-TED 기반 Cohen 등[6]이 대표적이며, 작용기, 물리화학적 성질, 약물 클래스에 대응하는 특성을 보고하였다. 그러나 SMI-TED는 SMILES 기반 트랜스포머 모델인 반면, 본 연구의 GEM[5]은 3차원 기하 정보를 활용하는 그래프 신경망으로 표현 방식이 다르다. 또한, BBBP[7]와 같은 데이터셋에서

1) 본 논문은 2026년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업(2023-0-00041), 정부(과학기술정보통신부)의 재원으로 한국연구재단(No. 2022RIC1C1005065), 과학기술정보통신부 및 정보통신기획평가원의 인공지능융합혁신인재양성사업(IITP-2026-RS-2023-00254177)의 지원을 받아 수행된 연구임

그래프 임베딩에 SAE를 적용해 약물 클래스 수준의 의미적 구조를 검증한 연구는 아직 제한적이다.




그림 1 GEM 그래프 임베딩에 sparse autoencoder(SAE)를 적용한 해석 프레임워크. (1) 원본 GEM 표현, (2) SAE 인코더에 의해 학습된 희소 잠재 표현, (3) SAE 디코더를 통한 복원 표현.

3. 방법

3.1 데이터셋 및 표현 학습 설정

본 연구에서는 MoleculeNet[7]의 BBBP, ClinTox, BACE 데이터셋을 사용하였으며, 모든 데이터셋은 scaffold split을 적용하여 학습, 검증, 시험 세트로 분할하였다. 분자 표현은 사전학습된 GEM[5] 모델을 사용하여 추출하였다. GEM은 원자 및 결합 정보뿐 아니라 결합 각도와 거리 등 3차원 기하 정보를 함께 학습하는 8층 그래프 신경망이다. 본 연구에서는 8번째 층에서 출력되는 그래프 단위 임베딩(32차원, 평균 풀링)을 기본 표현으로 사용하였다.

희소표현 학습을 위해 SAELens[4]의 JumpReLU sparse autoencoder[3]를 사용하였다. SAE는 32차원 밀집 표현을 1,024차원의 과완비 희소 사전으로 확장하여 재표현한다. 학습 시 임계값 초기값은 0.1, 희소성 손실 계수는 0.001로 설정하였으며, 평균 활성 값 기반 정규화를 적용하였다. 모델은 배치사이즈 4,096, learning rate 3×10^{-4} 로 30 epoch 동안 학습하였다.

3.2 분류 성능 및 해석 평가 설정

SAE 분해가 분류 성능에 미치는 영향을 평가하기 위해, 그림 1과 같이 (1) 원본 GEM 임베딩, (2) SAE 인코더 기반 희소 표현, (3) SAE 디코더 기반 복원 표현을 비교하였다. GEM 인코더와 SAE는 모두 고정(frozen)하였으며, 각 표현을 입력으로 동일한 분류 헤드를 처음부터 학습하였다. 분류 헤드는 LayerNorm과 3-layer MLP(은닉 차원 128, dropout 0.2)로 구성하였다. 모든 실험은 100 epoch 동안 학습률 1×10^{-3} , batch size 64로 수행하였으며, 5개 random seed에 대해 평균 ROC-AUC를 보고하였다.

각 feature(또는 GEM 뉴런)가 특정 약물 클래스를 얼마나 잘 구분하는지는 표적 집단과 비표적 집단 간 활성 값의 평균 차이를 두 집단의 변동성으로 정규화한 Cohen's d ($d = \mu_{\text{target}} - \mu_{\text{non-target}} / \sigma_{\text{pooled}}$)로 정의하였다. 여기서 μ_{target} , $\mu_{\text{non-target}}$ 는 각각 표적 및 비표적 집단의 평균 활성 값을 의미하며, σ_{pooled} 는 두 집단의 pooled standard deviation이다. d 값이 클수록 두 집단을 더 잘 분리하는 feature를 의미한다. GEM 뉴런의 경우 출력 부호에 따라 해석이 달라질 수 있으므로 sign sweep을 수행하여, 절댓값 기준으로 가장 큰 Cohen's d 를 최종 값으로 사용하였다.

4. 실험 결과




그림 2 SAE 학습 곡선: (a) 재구성 MSE, (b) 분자당 평균 활성 feature 수 L_0

표 2 다운스트림 데이터셋에서 표현방식 별 분류 성능 (ROC-AUC (std))

표현	차원	BBBP	clintox	BACE
원본	32	0.6660 (0.0078)	0.7018 (0.0361)	0.8337 (0.0333)
희소표현	32→1024	0.6534 (0.0104)	0.6903 (0.0249)	0.8107 (0.0120)
복원표현	32→1024→32	0.0660 (0.0087)	0.6913 (0.0300)	0.8384 (0.0359)

4.1 SAE 학습 검증과 밀집 표현의 희소화

실험 결과, SAE는 입력 그래프 임베딩의 정보를 거의 손실 없이 희소한 표현으로 변환하였다. ZINC15 임베딩에 대해 학

습된 SAE는 높은 설명 분산(0.9999)과 낮은 재구성 오차 (MSE 0.0026)를 보여, 원본 임베딩의 구조를 거의 완벽하게 보존함을 확인하였다. 동시에 표현 구조는 크게 변화하여, 1,024차원 중 평균 약 52.5개만 활성화되는 약 5% 수준의 희소성이 형성되었다. 반면 GEM 임베딩은 32차원 대부분이 동시에 활성화되는 밀집 표현을 보였다. 이는 SAE가 기존의 밀집 임베딩을 정보 손실 없이 희소 표현으로 재구성했음을 의미한다.

그림 2은 SAE 학습 과정에서 재구성 성능과 희소성 간의 변화 양상을 보여준다. 학습 초기에 재구성 오차는 빠르게 감소한 뒤 안정화되며, 동시에 활성 뉴런 수(L_0)는 점진적으로 감소하여 약 52.5 수준에서 수렴한다. 이는 SAE가 안정적으로 수렴하면서 재구성 성능과 희소성 사이의 균형점에 도달했음을 나타낸다.

4.2 다운스트림에서 표현방식 별 분류 성능 비교

본 실험에서는 희소 표현 학습 과정에서의 정보 손실 여부를 확인하기 위해 원본 표현, SAE 희소 표현, SAE 복원 표현을 이용한 분류 성능을 비교하였다. 그림 1에서 볼 수 있듯이 (1) 원본 표현은 GEM의 그래프 임베딩이며, (2) 희소표현과 (3) 복원표현은 각각 SAE의 인코더와 디코더를 통해 얻은 표현이다. 실험 결과, 모든 데이터 셋에서 세 표현 간 성능 차이는 크지 않았으며, 이는 표현 분해 과정에서도 분류에 필요한 정보가 대부분 보존됨을 의미한다 (표 1).

4.3 약물 클래스 단위 sparse feature




그림 3 SAE feature와 GEM neuron의 활성화 분포 및 클래스 분리 성능을 비교한 결과. x축은 활성화 값.

SAE의 일부 특성(feature)은 특정 약물 클래스를 구분하는 희소 축으로 작동함을 확인하였다. 각 feature의 활성화 분자 집합을 기반으로 표적 클래스를 정의하고, Cohen's d 를 통해 표적과 비표적 간 분리 정도를 정량화하였다. 비교를 위해 GEM의 32개 뉴런 중 동일 기준에서 가장 높은 Cohen's d 를 보이는 뉴런을 baseline으로 설정하였다. 실험 결과, 코르티코스테로이드(f690), 흡입 마취제(f819), 안트라사이클린(f675)에 대응하는 SAE feature는 각각 높은 효과 크기 (Cohen's $d = 3.90, 18.23, 6.86$)를 보였으며, 이는 동일 기준에서의 GEM 뉴런($d = 1.63, 4.26, 1.95$)보다 크게 높은 값이다. 이는 SAE 기반 희소 표현이 특정 약물 클래스에 대해 더 강한 분리 신호를 형성함을 시사한다. 이러한 차이는 그림 3에서 확인할 수 있듯이, SAE feature가 비표적 분자를 활성화 값 0 근처에 집중시키는 zero-floor 구조를 가지며 표적과 비표적을 명확히 분리하는 반면, GEM 뉴런은 두 집단의 활성화 분포가 크게 겹치는 양상을 보이는 데 기인한다.

그림 4은 SAE 특성이 특정 화학 구조적 모티프와 정렬됨을 보여준다. 각 feature(f690, f819, f675)는 각각 코르티코스테로이드, 흡입 마취제, anthracycline 계열 분자에서 선택




그림 4 각 SAE feature에 의해 선택적으로 활성화되는 대표 분자 구조

적으로 활성화되며, 활성화된 분자들은 공통적인 부분 구조를 공유하는 경향을 보인다.

5. 결론

본 연구에서는 GEM의 그래프 임베딩에 sparse autoencoder(SAE)를 적용하여 밀집된 분자 표현을 정보 손실 없이 희소한 고차원 표현으로 분해하고, 그 구조적 특성을 분석하였다. 학습된 SAE는 downstream 분류 성능을 유지하면서도 특정 약물 클래스와 정렬된 희소 특성을 형성하였으며, 기존 GEM 뉴런보다 더 높은 분리 능력을 보였다. 또한 시각화 결과, 이러한 희소 표현은 공통 화학 골격을 공유하는 약물군을 선택적으로 활성화하는 단일 의미 축으로 명확하게 나타났다. 이러한 결과는 분자 GNN 임베딩이 화학적으로 의미 있는 희소 표현 구조로 분해될 수 있음을 시사한다.

참고 문헌

- [1] T. Bricken et al., "Towards Monosemanticity: Decomposing Language Models with Dictionary Learning," Transformer Circuits Thread, 2023.
- [2] A. Templeton et al., "Scaling Monosemanticity: Extracting Interpretable Features from Claude 3 Sonnet," Anthropic, 2024.
- [3] S. Rajamanoharan et al., "Jumping Ahead: Improving Reconstruction Fidelity with JumpReLU Sparse Autoencoders," arXiv:2407.14435, 2024.
- [4] J. Bloom et al., "SAELens: Training and Analysis Toolkit for Sparse Autoencoders," GitHub: jbloomAus/SAELens, 2024.
- [5] X. Fang et al., "Geometry-Enhanced Molecular Representation Learning for Property Prediction," Nature Machine Intelligence, vol. 4, no. 2, pp. 127–134, 2022.
- [6] J. Cohen, A. G. Hasson, S. Tanovic, "Unveiling Latent Knowledge in Chemistry Language Models through Sparse Autoencoders," NeurIPS 2025 AI4Mat Workshop, 2025.
- [7] Wu, Z.; Ramsundar, B.; Feinberg, E. N.; Gomes, J.; Geniesse, C.; Pappu, A. S.; Leswing, K.; Pande, V. MoleculeNet: a benchmark for molecular machine learning. Chemical Science, 9, 2, 513–530, 2018.