

Sparse Autoencoder 기반 GNN 그래프 임베딩의 화학적 해석 가능 표현 분해


유진영¹, 노다솜², 김성훈¹, 권선영^{1,2,3}

¹부산대학교 의생명융합공학부, ²정보융합공학과, ³인공지능연구센터




연구 배경 및 관련 연구

- AI가 현재 분자 물성 예측에서 좋은 성능, 그러나 설명하지 못함
- 희소 오토 인코더(Sparse Autoencoder, SAE)는 은닉층을 입력보다 더 크게 확장시킨 오토인코더. 희소성 제약으로 입력마다 소수 차원만 활성화
→ 다의적 활성을 확장된 공간에서 하나의 차원이 하나의 단일 의미 특성과 대응하게 함




<희소 오토인코더 구조>





<예시>

연구 배경 및 관련 연구

- 자연어 모델의 Sparse Autoencoder
 - 희소 오토인코더로 트랜스포머의 내부 표현을 분해
→ 단일 개념에 대응하는 특성을 추출
 - 대규모 언어모델로 확장 → 추상적 개념 같은 고수준 의미 표현을 분리
- 화학·생체분자 표현에 대한 적용
 - SMI-TED 기반 SAE가 대표적, SMILES 시퀀스 기반 트랜스포머 임베딩 표현에 SAE를 적용



분자 그래프 학습 모델은 분자 시퀀스 학습 모델과 달리 분자 구조를 직접 학습하여 구조 정보 풍부



<분자 그래프>

CC(=O)OC1=CC=CC=C1C(=O)O

<분자 시퀀스>


→ 본 연구에서 분자 그래프 표현에 SAE를 적용해서 화학적 의미의 희소 표현으로 분해해보자

연구 목표

본 연구는 분자 그래프 표현에 SAE를 적용하여 세 질문에 답한다:

- Q1: 원본 표현을 희소 표현으로 분해해도 **정보가 보존**이 되는가?
- Q2: 학습된 희소 표현 특성이 원본 표현에 비해 **개념을 단일 차원으로 잘 분리**하는가?
- Q3: 학습된 희소 표현 특성이 **화학적으로 의미있는 구조**를 반영하는가?

제안 방법



입력 - GEM(사전학습, frozen)

결합 각도·거리 등 3차원 기하 정보를 학습하는 8층 GNN

왜 GEM인가?

Moleculenet 15개의 물성 벤치 마크에서 준수한 성능

8번째 층의 그래프 표현(32차원)을 기본 표현으로 사용

****JumpReLU SAE**를 사용하여 32차원의 표현을 1024차원의 희소 표현으로 재표현

✓ 희소 표현 평가 방법


1. 복원 **MSE**와 (1) 원본 표현 (2) 희소 표현 (3) 복원표현 3가지 표현에 대한 5 random seed 평균 **ROC-AUC**
2. 산점도와 **Cohen's d**를 통해 SAE 특성과 GEM 뉴런 표현의 정 성적, 정량적 비교
3. SAE 특성 활성 분자들이 **공통 구조를 공유**하는지 시각적으로 확인

제안 방법: 세부 설정

- SAE 학습: ZINC15 220만 분자 데이터
평가: MoleculeNet의 BBBP · ClinTox · BACE
임계값 초기값 0.1, 희소성 손실 계수 0.001
batch 4096, 30 epoch
- 분류 평가: GEM·SAE 고정, 각 표현 위에 동일 분류 헤드를 처음부터 학습
batch 64, 100 epoch

실험 결과

Q1: 원본 표현을 희소 표현으로 분해해도 정보가 보존이 되는가?



- (a) 재구성 학습 곡선 (가로축: Epoch / 세로축: 재구성 MSE)
MSE가 약 6.7×10^{-4} 까지 감소 후 수렴
→ 원본 임베딩 거의 완벽 복원


- (b) 희소성 곡선 (가로축: Epoch / 세로축: 분자당 평균 활성 특성 수 (L_0))
 $L_0 \approx 52.5 \rightarrow 1,024$ 차원 중 약 5%만 활성 = 희소 구조 형성

- ROC-AUC
세 표현 간 성능 차이 거의 없음

→ SAE가 정보 손실 없이 희소표현으로 분해

표현	차원	BBBP	clintox	BACE
원본	32	0.6660 (0.0078)	0.7018 (0.0361)	0.8337 (0.0333)
희소표현	32→1024	0.6534 (0.0104)	0.6903 (0.0249)	0.8107 (0.0120)
복원표현	32→1024→32	0.6660 (0.0087)	0.6913 (0.0300)	0.8384 (0.0359)

실험 결과




Q2: 학습된 희소 표현 특성이 원본 표현에 비해 **개념을 단일 차원으로 잘 분리하는가?**

- 좌: SAE 분해로 얻은 희소 특성 차원 1개, 우: 원본표현 32차원 중 1개 (가로축 = 활성화값 / 세로축 = BBBP 분자 데이터)
- 색점: SAE가 활성화되면서 **유사한 구조를 공유하는 분자군** / 회색점: 그 외 나머지
- 회색점(구조가 다른 분자군)이 0
→ 그 특성은 특정 분자 구조에만 활성화되는 깨끗한 스위치(단의미)
- ****Cohen's d 값**: 값이 클수록 하나의 차원이 하나의 의미에 대응함
→ 희소 특성 차원(좌) >> 원본 표현 차원(우)


→ **화학 개념이 SAE 단일 특성으로 단의미적 분리**

실험 결과


feat 690: Corticosteroid



prednisolone-hemisuccinate




methylprednisolone-acetate




prednisolone-tebutate


feat 819: Inhalational anesthetic



norflurane




desflurane




Teflurane


feat 675: Anthracycline



carubicin



idarubicin



medorubicin

Q3: 학습된 희소 표현 특성이 화학적으로 의미있는 구조를 반영하는가?

→ 희소 표현 특성이 활성화하는 분자군들을 시각화했을 때, 특정 약물 구조를 공유하는 등 화학적으로 유사한 구조를 가지고 있었음


결론

- GEM 그래프 표현에 SAE를 적용하여 정보 손실 없이 희소표현으로 분해가 가능
- SAE 학습을 통해 약물 클래스처럼 화학 구조를 단의미로 가지는 정렬된 희소 특성 형성

→ 분자 GNN 표현이 화학적으로 의미 있는 희소 표현 구조로 분해될 수 있음을
시

감사합니다

JumpReLU $_{\theta}(z)$



Cohen's d formula:

$$d = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2 + s_2^2}{2}}}$$
